

Глава 3. Нисходящий синтаксический анализ

3.4. $LL(1)$ -грамматики

3.4.4. Основные приемы преобразования КС-грамматик в $LL(1)$ -форму

Не существует полностью универсального автоматического процесса преобразования грамматик в $LL(1)$ -форму. Это связано с тем, что данная проблема алгоритмически неразрешима. Отсутствие общего решения проблемы не означает невозможности ее решения для частных случаев.

Во многих случаях КС-грамматики, которые не обладают $LL(1)$ -свойствами, можно преобразовать в $LL(1)$ -грамматики с помощью левой факторизации.

Рассмотрим это преобразование на примере следующей грамматики:

$$S \rightarrow aSb \mid aSc \mid \varepsilon$$

Определим множества направляющих символов (учитывая, что грамматика полна маркером конца строки $\perp$, т. е. в предположении, что в грамматике имеется продукция $S' \rightarrow S\perp$):

$$DS(S \rightarrow aSb) = \{a\},$$

$$DS(S \rightarrow aSc) = \{a\},$$

$$DS(S \rightarrow \varepsilon) = Follow(S) = \{b, c, \perp\}.$$

Направляющий символ a является общим для двух первых продукций, т. е. это не $LL(1)$ -грамматика. Применим для них правило левой факторизации (общим префиксом является aS). В результате получится $LL(1)$ -грамматика

$$S \rightarrow aSX \mid \varepsilon$$

$$X \rightarrow b \mid c$$

Таким образом, факторизация как бы выносит за скобки направляющие символы.

Многие языки программирования содержат такие часто используемые конструкции, как списки. Поэтому рассмотрим описание различных типов списков с помощью $LL(1)$ -грамматик.

Грамматика $L \rightarrow a ; L \mid a$ для порождения списка символов a , разделенных символом-разделителем (для определенности в качестве символа-разделителя используем точку с запятой), не обладает $LL(1)$ -свойствами. Применив левую факторизацию, получим $LL(1)$ -грамматику:

$$L \rightarrow aR$$

$$R \rightarrow ; aR \mid \varepsilon$$

Аналогично, применив левую факторизацию к продукциям $L \rightarrow aL \mid a$, порождающим список символов a без символов-разделителей, получим $LL(1)$ -грамматику

$$L \rightarrow aR$$

$$R \rightarrow aR \mid \varepsilon$$

Рассмотренные грамматики не допускают пустой список. Если это необходимо, то достаточно добавить в грамматики продукцию $L \rightarrow \varepsilon$. Для списка из нуля или более символов a возможно применение грамматики $L \rightarrow aL \mid \varepsilon$, но иногда она может оказаться непригодной для трансляции.

Следует отметить, что грамматика, содержащая левую рекурсию, не является $LL(1)$ -грамматикой. Рассмотрим продукции

$A \rightarrow A\alpha$ (леворекурсивная продукция по A),

$A \rightarrow a$

$DS(A \rightarrow A\alpha) = \{a\}$ и $DS(A \rightarrow a) = \{a\}$, т. е. множества направляющих символов пересекаются.

По тем же причинам грамматика, содержащая леворекурсивный цикл, не может быть $LL(1)$ -грамматикой.

Как уже отмечалось, левую рекурсию всегда можно исключить из грамматики, преобразовав ее в правую, которая не вызывает никаких проблем для нисходящего разбора.

После устранения левой рекурсии для получения $LL(1)$ -грамматики всегда требуется последующая левая факторизация. Можно сформулировать правило, объединяющее эти преобразования.

Пусть множество продукций содержит леворекурсивные productions $A \rightarrow A\alpha_1 | A\alpha_2 | \dots | A\alpha_m$ и все остальные A -продукции $A \rightarrow \beta_1 | \beta_2 | \dots | \beta_n$, не являющиеся леворекурсивными. Результатом устранения левой рекурсии будут productions

$$A \rightarrow \beta_1 | \beta_2 | \dots | \beta_n | \beta_1 A' | \beta_2 A' | \dots | \beta_n A'$$

$$A' \rightarrow \alpha_1 | \alpha_2 | \dots | \alpha_m | \alpha_1 A' | \alpha_2 A' | \dots | \alpha_m A'$$

Как видим, имеются productions с общими префиксами, поэтому выполним левую факторизацию:

$$A \rightarrow \beta_1 X | \beta_2 X | \dots | \beta_n X$$

$$X \rightarrow \varepsilon | A'$$

$$A' \rightarrow \alpha_1 X | \alpha_2 X | \dots | \alpha_m X$$

Выполнив замену вхождений нетерминала A' , получим окончательный результат:

$$A \rightarrow \beta_1 X | \beta_2 X | \dots | \beta_n X$$

$$X \rightarrow \varepsilon | \alpha_1 X | \alpha_2 X | \dots | \alpha_m X$$

Таким образом, модифицированное правило устранения левой рекурсии можно сформулировать следующим образом.

Пусть множество продукций содержит леворекурсивные продукции $A \rightarrow A\alpha_1 | A\alpha_2 | \dots | A\alpha_m$ и остальные A -продукции $A \rightarrow \beta_1 | \beta_2 | \dots | \beta_n$, не являющиеся леворекурсивными. Тогда новая эквивалентная грамматика будет иметь продукции вида:

$$\begin{aligned} A &\rightarrow \beta_1 X | \beta_2 X | \dots | \beta_n X \\ X &\rightarrow \varepsilon | \alpha_1 X | \alpha_2 X | \dots | \alpha_m X \end{aligned}$$

Для иллюстрации преобразуем в $LL(1)$ -форму следующую грамматику (предполагая наличие продукции $E' \rightarrow E\perp$):

$$\begin{aligned} E &\rightarrow E + T | T \\ T &\rightarrow T \times F | F \\ F &\rightarrow (E) | i \end{aligned}$$

Она не является $LL(1)$ -грамматикой, поскольку содержит леворекурсивные продукции. Применим рассмотренное выше модифицированное правило устранения левой рекурсии:

$$\begin{aligned} E &\rightarrow TX \\ X &\rightarrow + TX | \varepsilon \\ T &\rightarrow FY \\ Y &\rightarrow \times FY | \varepsilon \\ F &\rightarrow (E) | i \end{aligned}$$

Это $LL(1)$ -грамматика. Покажем это, определив множества направляющих символов для продукций с одинаковыми левыми частями:

$$DS(X \rightarrow + TX) = \{+\},$$

$$DS(X \rightarrow \varepsilon) = \{), \perp\},$$

$$DS(Y \rightarrow \times FY) = \{\times\},$$

$$DS(Y \rightarrow \varepsilon) = \{+,), \perp\},$$

$$DS(F \rightarrow (E)) = \{(\},$$

$$DS(F \rightarrow i) = \{i\}.$$

Множества направляющих символов всех пар альтернативных продукций не пересекаются, что позволяет при разборе строки детерминированно выбирать нужную продукцию.

Процесс вывода строки $i \times (i+i) \perp$ соответствует следующей левосторонней схеме вывода:

$$\begin{aligned} E' &\Rightarrow E \perp \Rightarrow TX \perp \Rightarrow FYX \perp \Rightarrow iYX \perp \Rightarrow i \times FYX \perp \Rightarrow i \times (E) YX \perp \\ &\Rightarrow i \times (TX) YX \perp \Rightarrow i \times (FYX) YX \perp \Rightarrow i \times (iYX) YX \perp \Rightarrow i \times (iX) YX \perp \\ &\Rightarrow i \times (i+TX) YX \perp \Rightarrow i \times (i+FYX) YX \perp \Rightarrow i \times (i+iYX) YX \perp \\ &\Rightarrow i \times (i+iX) YX \perp \Rightarrow i \times (i+i) YX \perp \Rightarrow i \times (i+i) X \perp \Rightarrow i \times (i+i) \perp. \end{aligned}$$

К сожалению, процесс факторизации нельзя распространить на общий случай. Следующий пример показывает, что может произойти. Рассмотрим грамматику

$$S \rightarrow Ac \mid Bd$$

$$A \rightarrow eAf \mid a$$

$$B \rightarrow eBg \mid b$$

Первые две S -продукции в своих множествах направляющих символов содержат общий символ e . Для проведения факторизации предварительно выполним замену вхождений нетерминалов A и B , чтобы направляющие символы явно присутствовали в этих продукциях:

$$S \rightarrow eAfc \mid ac \mid eBgd \mid bd$$

Выполняя факторизацию, эти продукции можно заменить следующими:

$$S \rightarrow ac \mid bd \mid eS_1$$

$$S_1 \rightarrow Afc \mid Bgd$$

Продукции для S_1 аналогичны первоначальным продукциям для S и имеют пересекающиеся множества направляющих символов. Можно повторить преобразование этих продукций, как это было сделано с продукциями для S

$$S_1 \rightarrow eAffc|afc|eBggd|bgd$$

В результате факторизации получим

$$S_1 \rightarrow afc|bgd|eS_2$$

$$S_2 \rightarrow Affc|Bggd$$

Продукции для S_2 аналогичны продукциям для S_1 и S , но длиннее их, и теперь очевидно, что этот процесс бесконечен.

Это означает, что все попытки преобразовать грамматику в $LL(1)$ -форму не всегда приводят к результату. Это прямое следствие того, что $LL(1)$ -языки – только подклассом более широкого класса языков, допускающих детерминированный разбор.

Другие примеры преобразования в $LL(1)$ -форму

Во всех рассматриваемых ниже грамматиках справа от продукций указаны множества направляющих символов (DS).

При выполнении левой факторизации для наглядности будем показывать вынос за скобки общих префиксов продукций, к которым применяется левая факторизация. Для этого будем применять скобки вида (и), они не входят в алфавит языка (не являются терминалами) и выполняют чисто иллюстративные функции.

Для начала рассмотрим $LL(3)$ -грамматику из темы 3.3.

$$S \rightarrow A\perp$$

$$A \rightarrow aFaB \mid bFbB$$

$$F \rightarrow b \mid ba$$

$$B \rightarrow b \mid bB$$

Вычислим DS .

$$S \rightarrow A\perp \quad \{a, b\}$$

$$A \rightarrow aFaB \quad \{a\}$$

$$A \rightarrow bFbB \quad \{b\}$$

$$F \rightarrow b \quad \{b\}$$

$$F \rightarrow ba \quad \{b\}$$

$$B \rightarrow b \quad \{b\}$$

$$B \rightarrow bB \quad \{b\}$$

DS пересекаются у F -продукций и B -продукций.

Факторизация продукций $F \rightarrow b \mid ba$ по префиксу b : $F \rightarrow b (\varepsilon \mid a)$

то, что в скобках обозначим новым нетерминалом X и получим

$$F \rightarrow bX \quad \{b\}$$

$$X \rightarrow \varepsilon \quad \{a, b\}$$

$$X \rightarrow a \quad \{a\}$$

Как видим, факторизация не привела к успеху, поскольку у X -продукций имеет место пересечение DS . Причина в продукции $X \rightarrow \varepsilon$, поскольку

$$DS(X \rightarrow \varepsilon) = Follow(X) = Follow(F) = \{a, b\},$$

т. е. зависят от A -продукций. Поэтому попробуем «продвинуть» направляющие символы в эти A -продукции заменой вхождений F по продукциям $F \rightarrow b \mid ba$. При этом отменяем эту факторизацию и добавление нетерминала X .

Замена вхождений F в A -продукциях $A \rightarrow aFaB \mid bFbB$ в соответствии с продукциями $F \rightarrow b \mid ba$: $A \rightarrow ababB \mid abaaB \mid bbbB \mid bbabB$

Факторизация $A \rightarrow ababB \mid abaaB$ по префиксу aba : $A \rightarrow aba (B \mid aB)$

то, что в скобках обозначим новым нетерминалом X и получим

$$A \rightarrow abaX \quad \{a\}$$

$$X \rightarrow B \quad \{b\}$$

$$X \rightarrow aB \quad \{a\}$$

Пока все хорошо.

Факторизация $A \rightarrow bbbB \mid bbabB$ по префиксу bb : $A \rightarrow bb (bB \mid abB)$

то, что в скобках обозначим новым нетерминалом Y и получим

$$A \rightarrow bbY \quad \{b\}$$

$$Y \rightarrow bB \quad \{b\}$$

$$Y \rightarrow abB \quad \{a\}$$

Тоже все нормально.

Осталось разобраться с продукциями $B \rightarrow b \mid bB$.

Факторизация $B \rightarrow b \mid bB$ по префиксу b : $B \rightarrow b (\varepsilon \mid B)$

то, что в скобках обозначим новым нетерминалом Z и получим

$$B \rightarrow bZ \quad \{b\}$$

$$Z \rightarrow \varepsilon \quad \{\perp\}$$

$$Z \rightarrow B \quad \{b\}$$

В итоге получили $LL(1)$ -грамматику

$S \rightarrow A\perp \quad \{a, b\}$

$A \rightarrow abaX \quad \{a\}$

$A \rightarrow bbY \quad \{b\}$

$X \rightarrow B \quad \{b\}$

$X \rightarrow aB \quad \{a\}$

$Y \rightarrow bB \quad \{b\}$

$Y \rightarrow abB \quad \{a\}$

$B \rightarrow bZ \quad \{b\}$

$Z \rightarrow \varepsilon \quad \{\perp\}$

$Z \rightarrow B \quad \{b\}$

или в сокращенной форме записи и без DS

$S \rightarrow A\perp$

$A \rightarrow abaX \mid bbY$

$X \rightarrow B \mid aB$

$Y \rightarrow bB \mid abB$

$B \rightarrow bZ$

$Z \rightarrow \varepsilon \mid B$

Рассмотрим еще пример. Помним про наличие продукции $S' \rightarrow S\perp$.

$$S \rightarrow AB$$

$$A \rightarrow Ba \mid \varepsilon$$

$$B \rightarrow Cb \mid C$$

$$C \rightarrow c \mid \varepsilon$$

Вычислим DS .

$$S \rightarrow AB \quad \{a, b, c, \perp\}$$

$$A \rightarrow Ba \quad \{a, b, c\}$$

$$A \rightarrow \varepsilon \quad \{b, c, \perp\}$$

$$B \rightarrow Cb \quad \{b, c\}$$

$$B \rightarrow C \quad \{a, c, \perp\}$$

$$C \rightarrow c \quad \{c\}$$

$$C \rightarrow \varepsilon \quad \{a, b, \perp\}$$

C -продукции удовлетворяют $LL(1)$ -свойствам (DS не пересекаются). Проблемы с B -продукциями и A -продукциями.

Можно было бы начать с факторизации B -продукций, но обратите внимание, что DS A -продукций формируются через B -продукции и C -продукции. Поэтому направляющие символы надо «продвигать» в A -продукции соответствующими заменами вхождений.

Замена вхождений C в B -продукциях $B \rightarrow Cb \mid C$ в соответствии с продукциями $C \rightarrow c \mid \varepsilon$ (при этом избавляемся от нетерминала C): $B \rightarrow cb \mid b \mid c \mid \varepsilon$

Факторизация $B \rightarrow cb \mid c$ по префиксу c : $B \rightarrow c(b \mid \varepsilon)$

то, что в скобках обозначим новым нетерминалом X и получим

$B \rightarrow cX \quad \{c\}$

$B \rightarrow b \quad \{b\}$

$B \rightarrow \varepsilon \quad \{a, \perp\}$

$X \rightarrow b \quad \{b\}$

$X \rightarrow \varepsilon \quad \{a, \perp\}$

Пересечений DS как B -продукций, так и X -продукций нет.

Замена вхождений B в A -продукциях $A \rightarrow Ba \mid \varepsilon$:

$A \rightarrow cXa \mid ba \mid a \mid \varepsilon$

Заметим, что в соответствии с продукцией $S \rightarrow AB$ (A и B – ε -порождающие)

$DS(A \rightarrow \varepsilon) = Follow(A) = First(B) \cup Follow(S) = \{b, c, \perp\}$,

т. е. $DS(A \rightarrow \varepsilon)$ пересекается с DS других A -продукций. «Продвинем» направляющие символы в продукцию $S \rightarrow AB$ соответствующими заменами вхождений.

Замена вхождений A в продукции $S \rightarrow AB$ в соответствии с продукциями $A \rightarrow cXa \mid ba \mid a \mid \varepsilon$: $S \rightarrow cXaB \mid baB \mid aB \mid B$

Замена вхождений B в продукции $S \rightarrow B$ (в других S -продукциях B не заменяем, поскольку они стоят после нетерминалов и не влияют на DS) в соответствии с продукциями $B \rightarrow cX \mid b \mid \varepsilon$: $S \rightarrow cXaB \mid baB \mid aB \mid cX \mid b \mid \varepsilon$

Теперь можно приступить к факторизации.

Факторизация $S \rightarrow cXaB \mid cX$ по префиксу cX : $S \rightarrow cX(aB \mid \varepsilon)$

то, что в скобках обозначим новым нетерминалом Y и получим

$$S \rightarrow cXY \quad \{c\}$$

$$Y \rightarrow aB \quad \{a\}$$

$$Y \rightarrow \varepsilon \quad \{\perp\}$$

Факторизация $S \rightarrow baB \mid b$ по префиксу b : $S \rightarrow b(aB \mid \varepsilon)$

то, что в скобках – это не что иное, как $Y \rightarrow aB \mid \varepsilon$, т. е. получим $S \rightarrow bY$.

В итоге получили грамматику:

$$S \rightarrow cXY \mid bY \mid aB \mid \varepsilon$$

$$X \rightarrow b \mid \varepsilon$$

$$Y \rightarrow aB \mid \varepsilon$$

$$B \rightarrow cX \mid b \mid \varepsilon$$

Можно сократить число продукций. Заметим, что продукция $S \rightarrow aB \mid \varepsilon$ – это не что иное, как $Y \rightarrow aB \mid \varepsilon$ (выделено желтым), т. е. можем заменить $aB \mid \varepsilon$ на Y . Аналогично продукция $B \rightarrow b \mid \varepsilon$ можем заменить на X (выделено зеленым). Получим

$$S \rightarrow cXY \mid bY \mid Y$$

$$X \rightarrow b \mid \varepsilon$$

$$Y \rightarrow aB \mid \varepsilon$$

$$B \rightarrow cX \mid X$$

Выполним правую факторизацию S -продукций: $S \rightarrow (cX \mid b \mid \varepsilon) Y$. В скобках не что иное, как $B \rightarrow cX \mid b \mid \varepsilon$. В итоге получаем грамматику

$$S \rightarrow BY$$

$$B \rightarrow cX \mid X$$

$$X \rightarrow b \mid \varepsilon$$

$$Y \rightarrow aB \mid \varepsilon$$

Докажем, что это $LL(1)$ -грамматика, вычислив DS .

$S \rightarrow BY \quad \{a, b, c, \perp\}$

$B \rightarrow cX \quad \{c\}$

$B \rightarrow X \quad \{a, b, \perp\}$

$X \rightarrow b \quad \{b\}$

$X \rightarrow \varepsilon \quad \{a, \perp\}$

$Y \rightarrow aB \quad \{a\}$

$Y \rightarrow \varepsilon \quad \{\perp\}$

Множества DS альтернативных продукций не пересекаются. Получили $LL(1)$ -грамматику.

И еще один пример

$$S \rightarrow abAd$$

$$A \rightarrow B \mid BeA$$

$$B \rightarrow fD$$

$$D \rightarrow t \mid teD$$

Вычислим DS

$$S \rightarrow abAd \quad \{a\}$$

$$A \rightarrow B \quad \{f\}$$

$$A \rightarrow BeA \quad \{f\}$$

$$B \rightarrow fD \quad \{f\}$$

$$D \rightarrow t \quad \{t\}$$

$$D \rightarrow teD \quad \{t\}$$

Факторизация $D \rightarrow t \mid teD$ по префиксу t : $D \rightarrow t (\varepsilon \mid eD)$

то, что в скобках обозначим новым нетерминалом X и получим

$$\begin{array}{ll} D \rightarrow tX & \{t\} \\ X \rightarrow \varepsilon & \{d, e\} \\ X \rightarrow eD & \{e\} \end{array}$$

Как видим, факторизация не привела к успеху, поскольку у X -продукций имеет место пересечение DS . Причина в продукции $X \rightarrow \varepsilon$, поскольку

$$DS(X \rightarrow \varepsilon) = Follow(X) = Follow(D) = Follow(B) \cup Follow(A) = \{d, e\},$$

т. е. зависят от A -продукций. Поэтому попробуем «продвинуть» направляющие символы в эти A -продукции заменой вхождений. При этом отменяем эту факторизацию и добавление нетерминала X .

Замена вхождений D в продукции $B \rightarrow fD$ в соответствии с productions $D \rightarrow t \mid teD$: $B \rightarrow ft \mid fteD$

Замена вхождений B в productions $A \rightarrow B \mid BeA$ в соответствии с productions $B \rightarrow ft \mid fteD$: $A \rightarrow ft \mid fteD \mid fteA \mid fteDeA$

Факторизация по префиксу ft : $A \rightarrow ft (\varepsilon \mid eD \mid eA \mid eDeA)$

то, что в скобках обозначим новым нетерминалом X и получим

$$A \rightarrow ftX$$

$$X \rightarrow \varepsilon \mid eD \mid eA \mid eDeA$$

Факторизация $X \rightarrow eD \mid eA \mid eDeA$ по префиксу e : $X \rightarrow e (D \mid A \mid DeA)$

то, что в скобках обозначим новым нетерминалом Y и получим

$$X \rightarrow \varepsilon \mid eY$$

$$Y \rightarrow D \mid A \mid DeA$$

Замена вхождений D в productions $Y \rightarrow D \mid DeA$ в соответствии с productions $D \rightarrow t \mid teD$: $Y \rightarrow t \mid teD \mid teA \mid teDeA$

Факторизация по префиксу t : $Y \rightarrow t (\varepsilon \mid eD \mid eA \mid eDeA)$

Заметим, что в скобках не что иное, как $X \rightarrow \varepsilon \mid eD \mid eA \mid eDeA$. Получаем $Y \rightarrow tX \mid A$.

В результате получаем грамматику

$$S \rightarrow abAd$$

$$A \rightarrow ftX$$

$$X \rightarrow \varepsilon \mid eY$$

$$Y \rightarrow tX \mid A$$

Вычислим DS :

$$S \rightarrow abAd \quad \{a\}$$

$$A \rightarrow ftX \quad \{f\}$$

$$X \rightarrow \varepsilon \quad \{d\}$$

$$X \rightarrow eY \quad \{e\}$$

$$Y \rightarrow tX \quad \{t\}$$

$$Y \rightarrow A \quad \{f\}$$

Множества DS альтернативных продукций не пересекаются. Получили LL(1)-грамматику.